




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



量子计算+深度学习：前沿研究

马汝辉 副教授、博导
计算机学院
上海交通大学

饮水思源 · 爱国荣校



1

量子计算+联邦学习

2

量子计算+强化学习

3

量子计算+大语言模型

01

量子计算+联邦学习



④ **定义：**联邦学习是一种分布式机器学习框架，允许多个设备或客户端协作训练共享模型，而原始数据不离开本地，从而保护数据隐私。

④ **联邦学习（FL）核心流程：**

- **本地训练：**客户端接收全局模型参数，使用私有数据集在本地进行训练，更新模型参数；
- **模型上传：**上传更新后的模型参数至服务器；
- **全局聚合：**服务器聚合上传的模型参数，更新全局模型参数；
- **模型收敛：**满足损失函数收敛条件时结束。

④ **关键优势：**联邦学习具有隐私保护、减少数据传输和利用边缘计算资源等优势，适用于数据隐私要求高且设备分布广泛的场景。



① 联邦学习的核心矛盾在于：隐私保护与通信效率的权衡。

② 根据网络拓扑，FL分为两类架构：依赖中心服务器的中心式FL vs 节点直连的分布式FL。二者特性将决定IoT场景的适配性。


③ 中心式 vs. 分布式FL：

□ 中心式FL：使用中央服务器（通常为云）统一聚合客户端模型参数。聚合逻辑清晰、训练收敛较快、通信开销低，但存在隐私泄露的可能。适用于资源相对充裕、通信稳定的环境。

□ 分布式FL：没有中心服务器，客户端之间以点对点（P2P）方式共享模型。鲁棒性强、解决隐私和通信瓶颈问题，但需付出高通信开销。更适合边缘计算/IoT等分布式异构设备。

联邦学习已有挑战以及解决方案——系统异构性

- ④ 系统异构性：终端设备间计算资源（如CPU硬件、电池）和无线信道不确定性（如信道争用）的差异。
- ④ 案例：在大规模物联网设备中，不同设备的硬件配置差异导致部分设备无法及时完成训练任务。





④ **预处理方法：在问题发生前主动预防（如异步通信和设备采样）。**


- 异步通信：服务器不再等待所有客户端完成上传，而是在收到部分客户端的本地模型更新后立即进行全局模型更新。
- 设备采样：在每一轮联邦训练中，服务器从全部客户端中选择部分设备参与训练与上传，而不是全体客户端参与。

④ **后处理方法：假设问题已存在并予以解决（如容错机制）。**

- 容错机制：为应对设备训练失败、通信中断或上传异常的情况，系统内置鲁棒性机制以保持联邦训练的稳定性与连贯性。

联邦学习已有挑战以及解决方案——统计异构性

- 统计异构性：由代理数据分布的非独立同分布（Non-IID）特性引起。物联网设备因其偏好和采样空间差异导致数据分布高度多样化，具体表现为数量偏斜（Quantity Skew）、特征分布偏斜（Feature Distribution Skew）和标签分布偏斜（Label Distribution Skew）。
- 案例：在医疗影像数据中，不同医院的数据分布差异较大，导致全局模型性能不佳。





④ 聚类：核心思想是分组相似客户端并为每组训练独立模型。

- 余弦相似度聚类：按梯度余弦相似度分组用户。
- 分布式聚类框架：代理估计组分配并返回梯度参数，在合成数据集上验证高效性。
- 混合剪枝：通过非结构化剪枝将相似标签代理分组，准确率提升30%。

④ 混合模型：

- pFedGP：基于高斯过程学习共享核函数，每个客户端使用个性化GP分类器。
- 组分混合：客户端协作学习潜在分布组分，并优化个性化混合权重。

④ 其他技术：


- 混合个性化框架：集成迁移学习、元学习和知识蒸馏。
- 超网络：中央超网络生成个性化模型，准确率显著提升。

案例：在金融数据中，攻击者可能通过模型反演获取用户隐私信息。

攻击类型与漏洞：

推理攻击：从梯度反推原始数据（成员推断/属性推断）。

投毒攻击：篡改本地模型→破坏全局模型（拜占庭攻击）





④ 隐私保护技术：

- 加密方法：高效但计算开销大。
- 扰动方法：隐私保证强但引入噪声难量化。
- 匿名方法：强隐私保证但性能下降。
- 混合方法：平衡隐私与效用，实现难度高。

④ 入侵检测系统 (Intrusion Detection System)：

- 联邦入侵检测系统 (FIDS) 因通信高效和快速训练成为研究热点。但仍有挑战：异常检测易产生误报（需处理数据不足和未标记问题）；DDoS攻击防御框架FLEAM通过增加攻击成本抑制恶意行为（准确率>90%）。



⊗ FL框架:

- ❑主流框架: TensorFlow Federated、PySyft、FATE、OpenFL、FedScale、Leaf (Non-IID数据集)、FedML (边缘计算)、Plato。
- ❑新兴框架: FEDJAX (基于JAX)、Flower。

⊗ 开放数据集:

- ❑基准数据集: MNIST、FEMNIST、CIFAR-10、Shakespeare、Sent140 等, 用于图像分类与 NLP 任务。
- ❑真实数据集: 覆盖推荐、人体活动识别、空气质量、COVID-19 影像等 13 类任务; 尚缺统一使用规范。
- ❑合成数据集: Dirichlet 分布、Synthetic 数据, 用于补充评估。



车联网

- 安全类：协作避撞、紧急预警，需低延迟。
- 非安全类：天气、加油站推荐，需提升交通效率。
- 挑战：频繁切换、带宽受限、图像质量差异、设备异构。
- 方案：契约设计、区块链+DAG 提升模型可靠性。

推荐系统

- 场景：内容推荐、移动任务推荐、自动驾驶策略推荐。
- 方案：PerFedRec利用联邦 GNN + 聚类 + 个性化模型，减少通信量。

智慧医疗

- 场景：跨医院协作、COVID-19 影像分析。
- 挑战：标签稀缺、数据/设备异构。
- 方案：迁移学习、个性化 FL、联邦 ResNet/CapsuleNet，在 3.4 万张 CT 上实现高准确率。



④ **量子优势：**量子计算凭借叠加、纠缠、干涉三大特性，可在特定问题上实现指数级加速。

□ **算力突破：**解决经典计算机无法处理的高复杂度数学问题（如支持向量机复杂度从 $O(NM)$ 降至 $O(\log(NM))$ ）。


□ **噪声鲁棒性：**QML模型在标签噪声（ μ ）增加时仍能保持学习能力。

□ **样本复杂度优势：**量子传感器与内存实现指数级样本效率提升（经Sycamore处理器验证）。

④ **联邦学习（FL）**在数据隐私、机密性或带宽受限的场景中极具价值，但面临计算效率低和隐私泄露的双重挑战。量子机器学习（QML）借助量子计算机的并行计算能力，有望在复杂模型训练和大规模数据处理方面为 FL 提供加速与安全保障，从而催生出量子联邦学习（QFL）这一新兴方向。

量子技术从根本上改变FL的实践场景：

- ❑ 隐私与安全：借助量子密钥分发（QKD）实现密钥的物理级安全共享；通过盲量子计算（BQC）在不解密数据的前提下完成模型聚合。
- ❑ 效率提升：利用量子瘦身机制（Slimming Mechanism）在训练过程中动态裁剪量子电路参数，既满足资源受限设备的实时性，又保留精度。
- ❑ 决策支持：量子电路本地训练可显著提升全局模型精度，为金融风控、医疗诊断等高价值场景提供快速且可信的决策依据。




核心量子模型

- 变分量子电路 (VQC) : 经典向量 $\rightarrow$ 量子编码 $\rightarrow$ 参数化量子门 $\rightarrow$ 测量输出。VQC 在仅数十个 qubit 的条件下即可达到或超越同等规模经典网络的表达能力, 且参数量更少、收敛更快。
- 量子卷积神经网络 (QCNN) : 将卷积与池化层替换为量子门, 可直接处理图像、视频等高维结构化数据。与 VQC 相比, QCNN 在特征提取深度与结构灵活性上更具优势。

QFL 框架

- 混合量子-经典 FL
- 变分 QFL (Variational QFL)
- QCNN 联邦学习 (首个“纯量子”QFL框架)





量子安全方案

- QKD (量子密钥分发) : 利用量子态不可克隆与窃听可检测特性, 为对称加密提供信息论安全的密钥共享。
- BQC (盲量子计算) : 客户端将加密量子态发送至不可信服务器, 服务器在不获知输入输出的情况下完成计算。
- GHZ 聚合: 所有客户端参数被编码至 GHZ 纠缠态, 任一 qubit 被篡改都会整体失真, 天然抵抗半诚实攻击者。



④ 提升 QFL 效率主要围绕两条主线：增强可扩展性与鲁棒性、降低量子网络开销。

④ 可扩展性与鲁棒性

- eSQNN 架构：将 Slimmable Neural Network 思想引入量子领域，利用深度可控的量子电路与 entanglement-controlled 门，实现参数动态裁剪与梯度保持，MNIST 准确率提升 11.7%。
- 动态 QFL：在瘦身 QNN 基础上增加可独立传输的 pole 参数，根据信道条件决定发送角度参数或 pole 参数，进一步降低通信量。

④ 降低网络开销

- 将变分量子算法 (VQA) 家族 (VQTN、QAOA、VQE) 嵌入 QFL，在 TensorFlow Quantum 上实现去中心化数据训练。结果表明，在 MNIST 数据集上较无 QFL 的基线算法取得更高分类精度，同时通信轮次显著减少。



④ 无线通信

□ 浅层 QNN 进行本地预测，云端聚合，但缺乏大规模实验验证。

④ 智慧城市

□ 卫星分发QKD密钥，地面节点结合可信执行环境（TEE）与安全多方计算（MPC），实现城市级协同推理与隐私保护。

④ 智能交通系统（ITS）

□ OQFL框架通过量子粒子群优化（QPSO）动态调参，将超参数组合编码为量子粒子，通过波函数演化寻找最优解。MNIST 实验显示，在多种对抗攻击下检测准确率均高于经典中心化方法。

④ QFL通过量子并行性解决FL的计算瓶颈，QKD/BQC提供理论完美的隐私保障。然而，NISQ设备的量子比特限制（ <100 qubits）和网络开销仍是产业化的核心障碍。随着量子硬件发展，QFL有望在医疗、金融等高安全需求场景率先落地。



⊗ **瓶颈：**在 IoT 场景下，通信与计算资源均受限。现有通信高效算法（如 FedAvg 及其变体）往往以增加本地计算轮次为代价来降低通信量，但这又抬高了终端能耗。

⊗ **未来方向：**

- 设计轻量级模型 + 边缘服务器协同计算，实现“通信-计算”联合最优；
- 开发带收敛保证的在线/异步算法，兼顾低时延与低功耗。



联邦学习的研究挑战——异构性诊断

④ **动态环境痛点：**现有工作多假设系统/统计异构性事先已知，且诊断方法（如本地相似度度量）通常在训练开始后才能启动，但物联网环境动态不可预测。

④ **开放问题：**

- 是否存在“零样本”或小样本即可完成的异构性诊断算法？
- 能否量化异构程度，并据此动态调整通信/计算策略，以降低整体开销？

④ **创新需求：**

- 设计无需/少轮训练的实时诊断算法（如局部相似性度量）。
- 量化异构程度 → 指导通信/计算资源动态分配。



④ 标记数据短缺：IoT 终端普遍缺乏大规模标注数据，传统梯度型监督方法难以直接应用。

④ 解决方案探索：

- 无监督/自监督 FL：利用聚类、对比学习、联邦自编码器等技术，在零/弱标签场景下保持精度；
- 核心问题：如何在无标记数据下精确度量数据相似性？



联邦学习的研究挑战——混合异构性FL算法

① 现实复杂性：系统异构（算力、网络）与统计异构（数据分布）往往并存，却被独立研究。

② 融合方法：

□ 联合优化：在全局-个性化模型之间通过知识蒸馏、元学习等手段同步处理两类异构；

□ 智能采样：综合考虑设备资源、数据多样性及模型陈旧度，设计公平且高效的客户端选择策略。



量子联邦学习的研究挑战——量子硬件局限性

⊗ NISQ设备瓶颈:

- 量子比特数限制 (<100 qubits) , 无法部署的大规模QFL规模;
- 量子噪声随电路深度呈指数累积, 难以通过纠错完全消除。系统异构 (算力、网络) 与统计异构 (数据分布) 往往并存, 却被独立研究。

⊗ 破局路径:

- 拓扑量子比特、低温控制、量子纠错-缓解协同设计;
- 为中等规模量子芯片设计“可扩展-可验证”的 QFL 协议。



④ 医疗/金融场景需求：QKD、BQC 等量子安全协议虽提供信息论保证，却伴随额外量子资源消耗；差分隐私-量子混合方案又可能放大噪声。

④ 开放问题：

- 如何设计“资源-安全”联合优化算法，在 qubit 数受限条件下最大化隐私保护强度？
- 可否将安全聚合（如 GHZ 态）与误差缓解技术耦合，实现“既安全又可控”的量子噪声环境？

④ 平衡方案：

- 优化量子算法（最小化资源消耗）
- 安全聚合协议（安全求和/安全中值）
- 加密-效用联合优化框架



④ 大规模QNN挑战:

- 量子梯度消失 → 局部收敛风险;
- 量子态振幅编码需要 2^n 维经典向量才能完整加载 n 维数据, 导致“输入维度灾难”。

④ 创新方向:

- 高效量子编码: qubit-efficient 编码[342]、张量网络压缩、可变深度编码;
- 分布式量子存储: 利用量子中继与量子互联网, 实现跨节点的量子数据并行加载与更新;
- 量子数据并行 vs. 模型并行: 在 qubit 受限时如何划分量子子模型并保证全局一致性?



量子联邦学习的研究挑战——其他开放问题

④ 训练可扩展性：大规模 QNN 中梯度呈指数衰减，导致本地模型难以收敛。

④ 量子网络建设：

□ 远距离量子设备互联（量子中继器研发）

□ 量子信道噪声抑制


④ 工程落地障碍：QFL 尚无统一基准数据集、评价指标与硬件-软件接口。

④ 无论是传统 FL 还是其量子增强形态 QFL，均需在计算-通信-隐私三角约束下寻求新的理论突破与系统创新。随着量子硬件、网络与算法的快速演进，我们有理由相信，上述挑战将在未来 5–10 年内逐步被攻克，QFL 终将成为大规模、隐私保护的分布式机器学习的重要范式。

02

量子计算+强化学习


- ④ 强化学习可以追溯到控制论早期以及统计学、心理学、神经科学和计算机科学领域的研究。在过去五到十年中，它迅速引起了机器学习和人工智能领域的广泛关注。
- ④ 与通常被归类为“被动学习”的监督学习与非监督学习方法相比，强化学习（RL）属于交互式学习。
- ④ 强化学习是一种通过奖惩机制对智能体进行编程的方法，而无需明确指定任务如何完成。
- ④ 强化学习系统一般包括四个要素：策略（policy），奖励（reward），价值（value）以及环境。



① 在标准强化学习模型中，智能体通过感知和行为与环境进行交互。在每一步，智能体接收某种形式的输入（即当前状态的指示），然后选择一个动作。该动作会改变环境状态，产生一个新的状态，并将状态转移的值作为奖励反馈给智能体。

② 形式上，该模型由以下部分组成：

- 离散环境状态集合 S ；
- 离散动作集合 A ；
- 标量强化信号集合（通常为 $\{0,1\}$ 或实数） ；



标准强化学习模型



今天的介绍主要围绕RL和Quantum一下几个方面进行介绍

- 基于量子态叠加原理的量子强化学习
- 基于变分量子电路的量子强化学习
- 面向量子强化学习的投影模拟
- 用于量子强化学习的玻尔兹曼机
- 量子策略与价值迭代



基于量子态叠加原理的量子强化学习

④ C.-L. Chen等人提出了首个在在线量子强化学习 (Quantum Reinforcement Learning, QRL) 中实现对数级最坏情况遗憾值 (logarithmic worst-case regret) 的算法框架。作者设计了面向表格型 MDP和线性混合MDP的两种量子UCRL算法 (Quantum UCRL 和 Quantum UCRL- VTR) , 通过结合量子幅度估计、特征估计与延迟更新 (lazy updating) 等新技术

Algorithm 1 Quantum UCRL

```

1: Input: failure probability  $\delta$ .
2: Initialize for each  $\forall (s, a, h) \in \mathcal{S} \times \mathcal{A} \times [H]$ : (i) the counter  $n_h(s, a) := 0$  and tag  $l_h(s, a) := 0$ ; (ii) the empirical model  $\hat{\mathcal{P}}_h(\cdot | s, a) := \text{Unif}(\mathcal{S})$ ; and (iii) the set of quantum samples  $\mathcal{D}_h(s, a) := \emptyset$ .
3: Initialize the exploration policy  $\pi^1$  as a uniform policy.
4: for phase  $k = 1, 2, \dots, \lceil T/H \rceil$  do
5:   for step  $h = 1, 2, \dots, H$  do
6:     Call  $s_h^k := \text{CSQA}(\pi^k, h)$  (Algorithm 6), define  $a_h^k := \pi_h^k(s_h^k)$ .
7:     Define  $|\bar{\varphi}_{k,h+1}\rangle := \hat{\mathcal{P}}_h|s_h^k, a_h^k\rangle|0\rangle$  and  $|\bar{\varphi}_{k,h+1}^{-1}\rangle := \hat{\mathcal{P}}_h^{-1}|s_h^k, a_h^k\rangle|0\rangle$ .
8:     Add  $\{|\bar{\varphi}_{k,h+1}\rangle, |\bar{\varphi}_{k,h+1}^{-1}\rangle\}$  to  $\mathcal{D}_h(s_h^k, a_h^k)$ .
9:     Add the counter  $n_h(s_h^k, a_h^k)$  by 1.
10:    if  $n_h(s_h^k, a_h^k) = 2^{l_h(s_h^k, a_h^k)}$  then
11:      Update  $\hat{\mathcal{P}}_h(\cdot | s_h^k, a_h^k)$  by calling quantum subroutine (Lemma 3.1) with  $\mathcal{D}_h(s_h^k, a_h^k)$ .
12:      Add the tag  $l_h(s_h^k, a_h^k)$  by 1.
13:      Set  $\mathcal{D}_h(s_h^k, a_h^k) = \emptyset$ .
14:    end if
15:  end for
16:  Set  $V_{H+1}(s) = 0, \forall s \in \mathcal{S}$ .
17:  for  $h = H, H-1, \dots, 1$  do
18:    Set bonus term  $b_h(s, a) := \tilde{\mathcal{O}}(HS/n_h(s, a))$ .
19:    Update  $Q, V$  by (4.2) and (4.3).
20:    Set  $\pi_h^{k+1}(s) := \arg\max_a Q_h(s, a)$ .
21:  end for
22: end for

```


Algorithm 2 Quantum UCRL-VTR

```

1: for phase  $k = 1, \dots, K$  do
2:   Calculate  $\{\bar{\theta}_h^k\}_{h \in [H]}$  and  $\{\Lambda_h^k\}_{h \in [H]}$  as (5.3).
3:   Construct the confidence set  $\mathcal{C}^k = \{\mathcal{C}_h^k\}_{h \in [H]}$  as (5.4).
4:    $(\{Q_h^k\}_{h \in [H]}, \{V_h^k\}_{h \in [H]}, \{\pi_h^k\}_{h \in [H]}) \leftarrow \text{Optimistic Planning}(\mathcal{C}^k)$  (Algorithm 3).
5:    $\{\hat{\phi}_h^k\}_{h \in [H]} \leftarrow \text{Estimate Feature}(\{\Lambda_h^k\}_{h \in [H]})$  (Algorithm 4).
6:   Set  $w_k \leftarrow \max_{h \in [H]} \|\hat{\phi}_h^k\|_{(\Lambda_h^k)^{-1}}$ .
7:    $\{y_h^k\}_{h \in [H]} \leftarrow \text{Estimate Regression Target}(\pi^k, V^k, w_k)$  (Algorithm 5).
8: end for

```


H. Zhong et al. "Provably Efficient Exploration in Quantum Reinforcement Learning with Logarithmic Worst-Case Regret". arXiv:2302.10796 (2023). doi: 10.48550/ arXiv.2302.10796.





基于量子态叠加原理的量子强化学习

- ⑧ C.Chen等人分析了量子强化学习 (QRL) 的复杂度, 提出并定义了存储复杂度和探索复杂度两个指标, 通过公式推导和实验对比, 说明了在相同状态数和动作数下, QRL在存储需求和探索步数上相较经典RL更具优势, 并给出了在不同场景下的量化结果, 进一步完善了QRL的理论体系。




RL 与 QRL 的探索复杂度对比

Chen C, Dong D. Complexity analysis of Quantum reinforcement learning[C]//Proceedings of the 29th Chinese Control Conference. IEEE, 2010: 5897-5901.

基于量子态叠加原理的量子强化学习

- 针对将量子系统从初始混态驱动至目标纯态的问题，D. Dong等人提出了一种混合控制方法结合了相干控制（coherent control）和非相干控制（measurement-based control），以获得更优的性能。具体而言，量子增强强化学习（QRL）被用于控制器设计中，以学习最优控制策略。




包含概率模糊估计器（PFE）和 QRL 的混合控制结构

D. Dong et al. "Robust Quantum-Inspired Reinforcement Learning for Robot Navigation". IEEE/ASME Trans Mechatron 17.1 (2012), 86. doi: 10.1109/TMECH.2010.2090896.



基于变分量子电路的量子强化学习

- 针对变分量子电路 (Variational Quantum Circuits, VQC) 在深度强化学习中的应用。S. Y.-C. Chen等人将经典深度强化学习算法 (如经验回放与目标网络) 重构为变分量子电路的表示形式。此外，我们引入了一种量子信息编码方法，用以减少相较于经典神经网络的模型参数数量。



用于变分量子深度强化学习 (DRL) 智能体的 Frozen-Lake 环境


S. Y.-C. Chen et al. "Variational Quantum Circuits for Deep Reinforcement Learning".
IEEE Access 8 (2020), 141007. doi: 10.1109/access.2020.3010470.






基于变分量子电路的量子强化学习

- 针对解决基于深度Q学习算法的离散和连续状态空间下的强化学习任务，A. Skolik等人探究了对于量子Q学习智能体来说，哪些结构设计最有助于在不同环境中成功求解问题。通过对多种数据编码和读出策略的消融实验，作者深入理解了基于VQA的Q学习算法的性能为什么严重依赖于量子模型中的可观测量，并展示了如何根据具体任务选择合适的可观测量。
- 为了与经典的DQN算法进行比较，作者对不同参数量的PQC和NN进行了大量的超参数搜索。



(a) average scores



(b) mean absolute error with optimal Q-values


不同深度量子智能体在Frozen Lake环境中的表现及其与最优Q值的接近程度

A. Skolik, S. Jerbi, and V. Dunjko. “Quantum agents in the Gym: a variational quantum algorithm for deep Q-learning”. Quantum 6 (2022), 720. doi: 10.22331/q-2022-05-24-720.



基于变分量子电路的量子强化学习

- 针对现实量子设备中常见的噪声问题，A. Skolik等人提出了一种鲁棒性更强的变分量子强化学习框架。该方法在Q-learning和policy gradient两类算法下，通过引入目标网络减少测量次数、建立参数扰动模型分析量子电路的鲁棒性，并设计了综合多种典型噪声的定制噪声模型。实验证明，在面对不同类型的量子噪声（包括shot noise、相干误差和非相干误差）时，所提出的量子强化学习方法表现出良好的稳定性和收敛性，展现出在近似现实条件下实现量子优势的潜力。




基于变分量子算法的强化学习框架与多源噪声鲁棒性测试

A. Skolik et al. "Robustness of quantum reinforcement learning under hardware errors".
EPJ Quantum Technol. 10.1 (2023), 1. doi: 10.1140/epjqt/s40507-023-00166-1.

面向量子强化学习的投影模拟


④ A. A. Melnikov等人提出了一种基于“投影仿真 (Projective Simulation, PS)”的量子强化学习框架，能在不依赖经典梯度优化的前提下，通过“经验剪辑网络”实现学习与泛化。该模型利用记忆结构中的随机漫步机制，使得智能体在面对变化的环境刺激时，能快速学习并做出反应，尤其在复杂或资源受限的量子任务中展现出鲁棒性。



Projective Simulation剪辑网络与泛化机制示意图

面向量子强化学习的投影模拟


- ⑧ H. J. Briegel等人提出了一种名为“投影模拟 (Projective Simulation, PS)”的学习框架，它通过一个随机跳跃的记忆网络来模拟智能体对未来行为的“想象”。在与环境交互之前，智能体在内存网络中基于以往经验激活记忆片段，通过模拟不同可能的行动路径，从而做出更合理的决策。这种方法引入了内在的反思与模拟机制，并被进一步扩展至量子版本，用于量子强化学习任务中，展示了其在学习泛化与应对复杂情境中的显著潜力。



投影模拟网络的结构与泛化机制

H. J. Briegel and G. De las Cuevas. “Projective simulation for artificial intelligence”.
Sci. Rep. 2.1 (2012), 1. doi: 10.1038/srep00400.

- ④ V. Dunjko等人提出了一种名为“投影模拟 (Projective Simulation, PS)”的学习框架，它通过一个随机跳跃的记忆网络来模拟智能体对未来行为的“想象”。在与环境交互之前，智能体在内存网络中基于以往经验激活记忆片段，通过模拟不同可能的行动路径，从而做出更合理的决策。这种方法引入了内在的反思与模拟机制，并被进一步扩展至量子版本，用于量子强化学习任务中，展示了其在学习泛化与应对复杂情境中的显著潜力。




投影模拟智能体架构图

V. Dunjko, N. Friis, and H. J. Briegel. “Quantum-enhanced deliberation of learning agents using trapped ions”. New J. Phys. 17.2 (2015), 023006. doi: 10.1088/1367-2630/17/2/023006.

用于量子强化学习的玻尔兹曼机

- ⑧ S. Jerbi等人提出了一种基于玻尔兹曼机的量子强化学习框架，结合能量模型与深度学习技术，显著提升了强化学习在大规模状态-动作空间下的泛化能力和采样效率，展示了量子增强学习在深度RL中的潜在优势。




价值函数近似方式对比：DQN 与深度能量模型网络

S. Jerbi et al. “Quantum Enhancements for Deep Reinforcement Learning in Large Spaces”.
Phys. Rev. X Quantum 2.1 (2021), 010328. doi: 10.1103/PRXQuantum.2.010328.

用于量子强化学习的玻尔兹曼机

- ⑧ M. Schenk等人提出了一种混合量子强化学习架构，将经典Actor-Critic结构中的Critic模块替换为基于量子玻尔兹曼机（QBM）的自由能函数，以更高效地估计状态-动作值函数，从而提升在连续状态-动作空间中的学习性能与样本效率。




基于QBM的量子强化学习Actor-Critic框架

M. Schenk et al. "Hybrid actor-critic algorithm for quantum reinforcement learning at cern beam lines". arXiv:2209.11044 (2022). doi: 10.48550/arXiv.2209.11044.



用于量子强化学习的玻尔兹曼机

- ④ A. Levit等人提出了一种基于自由能的量子强化学习 (FERL) 方法, 利用深度玻尔兹曼机 (DBM) 建模 Q 函数, 并通过量子退火实现自由能估计, 显著提高了训练早期策略的收敛性能。研究结合副本堆叠技术 (Replica Stacking) 与 D-Wave 量子芯片对 Q 值函数进行拟合, 实验证明该方法在典型网格世界任务中优于传统的 DQN 与经典玻尔兹曼方法。



基于QBM的量子强化学习Actor-Critic框架

A. Levit et al. "Free energy-based reinforcement learning using a quantum processor"
arXiv:1706.00074 (2017). doi: 10.48550/arXiv.1706.00074.





量子策略与价值迭代

- ④ D. Wang等人提出了一类基于量子计算的强化学习算法，用于高效求解马尔可夫决策过程（MDP）中的最优策略（ π^* ）、最优值函数（ v^* ）和最优Q函数（ q^* ）。研究表明，在允许访问环境的量子生成模型（quantum generative model）前提下，这些量子算法可以在近似精度 ϵ 和动作空间大小 $|A|$ 的复杂度指标下，实现对经典算法的平方级加速。此外，论文还提出了与下界相匹配的算法，证明其在样本复杂度上已达最优。

Goal: output an ϵ -accurate estimate of	Classical sample complexity	Quantum sample complexity	
	Upper and lower bound	Upper bound	Lower bound
q^*	$\frac{SA\Gamma^3}{\epsilon^2}$	$\frac{SA\Gamma^{1.5}}{\epsilon}$ [Theorem 5]	$\frac{SA\Gamma^{1.5}}{\epsilon}$ [Theorem 8]
v^*, π^*	$\frac{SA\Gamma^3}{\epsilon^2}$	$\frac{SA\Gamma^{1.5}}{\epsilon}$ [Theorem 5] $\frac{S\sqrt{A}\Gamma}{\epsilon}$ [Theorem 7]	$\frac{S\sqrt{A}\Gamma^{1.5}}{\epsilon}$ [Theorem 8]

基于QBM的量子强化学习Actor-Critic框架

D. Wang et al. “Quantum algorithms for reinforcement learning with a generative model”. International Conference on Machine Learning (ICML) 139 (2021), 10916.
url: <https://proceedings.mlr.press/v139/wang21w.html>.





- ⑧ B. Ganguly等人提出了一种基于量子计算的强化学习算法，用于高效求解马尔可夫决策过程（MDP）中的最优策略和最优值函数问题。该方法结合了量子均值估计和量子最大值搜索技术，显著降低了样本复杂度，实现了在近似精度 ε 和折扣因子 γ 给定的情况下，对最优策略 π^* 、最优值函数 v^* 以及最优动作值函数 q^* 的平方级加速估计。该算法在理论上证明了其样本复杂度达到经典算法下界，展示了量子强化学习在实际环境中的潜在优势。

B. Ganguly et al. "Quantum Computing Provides Exponential Regret Improvement in Episodic Reinforcement Learning". arXiv:2302.08617 (2023). doi: 10.48550/arXiv.2302.08617.





- ⑧ H. Zhong等人提出了首个具备对数级最坏情况下后悔界 (logarithmic worst-case regret bound) 的在线量子强化学习算法框架，分别针对表格型 MDP 和线性混合 MDP 场景，设计了 Quantum UCRL 与 Quantum UCRL-VTR 两种算法。通过引入量子均值估计、稀疏样本重用、策略评估结构与懒更新机制，论文在不依赖马尔可夫集中不等式的前提下，有效突破了经典 RL 中的 后悔界限。

Algorithm 1 Quantum UCRL

```
1: Input: failure probability  $\delta$ .
2: Initialize for each  $\forall (s, a, h) \in \mathcal{S} \times \mathcal{A} \times [H]$ : (i) the counter  $n_h(s, a) := 0$  and tag  $l_h(s, a) := 0$ ; (ii)
   the empirical model  $\hat{\mathcal{P}}_h(\cdot | s, a) := \text{Unif}(\mathcal{S})$ ; and (iii) the set of quantum samples  $\mathcal{D}_h(s, a) := \emptyset$ .
3: Initialize the exploration policy  $\pi^1$  as a uniform policy.
4: for phase  $k = 1, 2, \dots, \lceil T/H \rceil$  do
5:   for step  $h = 1, 2, \dots, H$  do
6:     Call  $s_h^k := \text{CSQA}(\pi^k, h)$  (Algorithm 6), define  $a_h^k := \pi_h^k(s_h^k)$ .
7:     Define  $|\bar{\varphi}_{k,h+1}\rangle := \hat{\mathcal{P}}_h|s_h^k, a_h^k\rangle|0\rangle$  and  $|\bar{\varphi}_{k,h+1}^{-1}\rangle := \hat{\mathcal{P}}_h^{-1}|s_h^k, a_h^k\rangle|0\rangle$ .
8:     Add  $\{|\bar{\varphi}_{k,h+1}\rangle, |\bar{\varphi}_{k,h+1}^{-1}\rangle\}$  to  $\mathcal{D}_h(s_h^k, a_h^k)$ .
9:     Add the counter  $n_h(s_h^k, a_h^k)$  by 1.
10:    if  $n_h(s_h^k, a_h^k) = 2^{l_h(s_h^k, a_h^k)}$  then
11:      Update  $\hat{\mathcal{P}}_h(\cdot | s_h^k, a_h^k)$  by calling quantum subroutine (Lemma 3.1) with  $\mathcal{D}_h(s_h^k, a_h^k)$ .
12:      Add the tag  $l_h(s_h^k, a_h^k)$  by 1.
13:      Set  $\mathcal{D}_h(s_h^k, a_h^k) = \emptyset$ .
14:    end if
15:  end for
16:  Set  $V_{H+1}(s) = 0, \forall s \in \mathcal{S}$ .
17:  for  $h = H, H-1, \dots, 1$  do
18:    Set bonus term  $b_h(s, a) := \tilde{\mathcal{O}}(HS/n_h(s, a))$ .
19:    Update  $Q, V$  by (4.2) and (4.3).
20:    Set  $\pi_h^{k+1}(s) := \text{argmax}_a Q_h(s, a)$ .
21:  end for
22: end for
```

Quantum UCRL (Upper Confidence Reinforcement Learning) 算法的主流程

H. Zhong et al. “Provably Efficient Exploration in Quantum Reinforcement Learning with Logarithmic Worst-Case Regret”. arXiv:2302.10796 (2023). doi: 10.48550/arXiv.2302.10796.





03

量子计算+大语言模型



大语言模型回顾


近年来，随着深度学习技术的创新和演进，大语言模型（Large Language Model, LLM）已成为人工智能领域的核心突破之一。





大语言模型回顾

- 大语言模型的参数规模呈现出爆炸式增长，从2018年BERT和GPT-1的几亿参数，迅速发展到了GPT-3、PaLM等千亿参数规模，最新的GPT-4等模型甚至接近万亿级。参数量的持续扩张为模型带来了更强的语言理解与生成能力，成为大语言模型性能跃迁的重要支撑。





PQC-based Quantum Transformers

QKV-only Quantum Mapping

• 核心思想:

- 将Transformer中Q / K / V生成步骤用参数化量子电路 (PQC) 替代
- 生成的Q、K、V经过量子测量得到经典向量
- 注意力矩阵计算仍保持经典 (Softmax)
- 实现量子特征映射增强与经典Transformer兼容

• 方法流程:

- 输入数据 → 编码为量子态 → 三个独立PQC生成。将测量得到经典Q/K/V，参与经典Softmax注意力计算。

• 优势:

- 结构简单，易与经典Transformer兼容

• 局限:

- 注意力计算仍是经典操作

$$|\psi_Q\rangle = U_Q(\theta_Q)|\psi(x)\rangle$$

$$|\psi_K\rangle = U_K(\theta_K)|\psi(x)\rangle$$

$$|\psi_V\rangle = U_V(\theta_V)|\psi(x)\rangle$$





Quantum Pairwise Attention

• 核心思想:

- 将Transformer中的注意力分数 (QK^T) 计算, 用量子算法直接在量子态之间计算
- 保留Q/K/V为量子态, 不再测量转为经典向量;
- 利用Swap Test、Hadamard Test 或 量子核方法直接求出量子态间的相似度
- 实现了真正量子化的注意力分数矩阵计算, 减少量子-经典切换

• 流程:

- 过在量子态之间直接计算成对相似度生成注意力矩阵, 完成量子化的注意力机制

• 优势:

- 利用量子态空间增强Q、K、V的特征表达能力, 结构简单, 易与经典Transformer结合。

• 局限:

- 注意力计算仍为经典 $O(N^2)$, 量子-经典测量开销不可避免

$$|\psi_Q^i\rangle, |\psi_K^j\rangle, |\psi_V^j\rangle$$

$$A_{i,j} = |\langle \psi_Q^i | \psi_K^j \rangle|^2$$





PQC-based Quantum Transformers

Quantum Holistic Attention

• 核心思想:

- 不再成对计算Q与K之间的相似度, 通过整体量子变换直接对所有tokens进行全局混合, 在量子态空间实现全局信息交互
- 类似MLP-Mixer的思想, 但用参数化量子电路完成全局特征融合优势:

• 方法流程:

- 通过整体量子变换直接对所有输入tokens完成全局信息混合

$$|\Psi_{\text{input}}\rangle = |\psi_1\rangle \otimes |\psi_2\rangle \otimes \cdots \otimes |\psi_N\rangle$$

$$|\Psi_{\text{output}}\rangle = U_{\text{global}}(\theta) |\Psi_{\text{input}}\rangle$$

• 优势:

- 整体量子变换实现全局信息混合, 减少参数并避免复杂的pairwise相似度计算。

$$\text{Output Features} = \text{Measurement}(|\Psi_{\text{output}}\rangle)$$

• 局限:

- 缺少显式注意力矩阵, 不易解释, 且依赖特殊量子门设计。





QLA-based Quantum Transformers

- **核心思想:**

- QLA-based Quantum Transformers是一种利用量子线性代数算法加速Transformer中矩阵运算的架构，旨在实现理论上的量子加速。
- 关注矩阵层面的量子加速，例如注意力矩阵计算、前馈网络中的矩阵乘法
- 目标是实现理论上的指数加速，但依赖容错量子计算机

- **方法流程:**

- 通过将Transformer中的矩阵运算（如注意力矩阵和前馈网络）转换为量子矩阵操作，利用量子线性代数算法在量子态空间中完成加速计算。

- **优势:**

- 可在矩阵层面实现理论上的指数级量子加速

- **局限:**

- 依赖容错量子计算机，目前仅限于理论研究阶段

$$A \approx \alpha \cdot \langle 0^a | U_A | 0^a \rangle$$

$$P(A) = V_A \cdot P(D_A) \cdot V_A^\dagger$$

$$|A\vec{x}\rangle = U_A|\vec{x}\rangle$$





④ 当前量子Transformer模型在小规模任务和资源受限场景下，展示出初步的量子优势，优势主要体现在特征表达增强和模型参数效率两方面。

- 实验验证：

- 小规模分类任务（NLP / CV）：量子模型在文本分类、图像分类中与甚至优于经典模型
- 多领域应用：计算机视觉（CV）、自然语言处理（NLP）、量子化学、粒子物理和时间序列与金融建模等。
- 具体优势：在参数量更少的情况下取得相似或更好的性能，在资源受限（小数据、小模型）下更加有效。

- 应用：

- QSANN、HQViT等量子模型在真实量子硬件上完成验证。
- 高能物理任务中表现出良好适应性。
- 应用于Navier–Stokes方程求解等科学计算问题。



当前的挑战

- 大多数PQC-based量子Transformer在计算复杂度上，仍存在经典方法的 $O(N^2)$ 瓶颈，计算负担转化为对量子比特数量、量子电路深度以及测量次数的高资源需求。不同方法在量子资源开销与剩余经典计算负载之间的权衡关系，揭示了现阶段量子模型在硬件资源受限条件下面临的实际复杂度挑战。

Category	Model	#Qubits	Circuit depth	#Measurement per time	Circuit execution times	#Total measurement	Outputs of quantum circuits	Remaining classical complexity
QKV-only Quantum mapping	[20]	$O(d)$	$O(\text{poly}(d))$	$O(d)$	$O(N)$	$O(Nd)$	$\{\mathbf{q}_i\}_{i=1}^N, \{\mathbf{k}_i\}_{i=1}^N, \{\mathbf{v}_i\}_{i=1}^N$	$O(N^2d)$
	[21]	$O(d)$	$O(\text{poly}(d))$	$O(d)$	$O(N^2)$	$O(N^2d)$	$\{A_{ij}\}_{i,j=1}^N, \{\mathbf{v}_i\}_{i=1}^N$	$O(N^2d)$
Quantum pairwise attention	[39]	$O(\log(Nd))$	$O(\text{poly}(\log d))^*$	$O(\log d)$	$O(N^2)$	$O(N^2 \log d)^{**}$	$\{A_{ij}\}_{i,j=1}^N, \{\mathbf{v}_i\}_{i=1}^N$	$O(N^2d)$
	[40]	$O(d)$	$O(\text{poly}(d))$	$O(d)$	$O(N^2)$	$O(N^2d)$	$\{A_{ij}\}_{i,j=1}^N, \{\mathbf{v}_i\}_{i=1}^N$	$O(N^2d)$
	[22] ¹	$O(d)$	$O(\text{poly}(d))$	$O(d)$	$O(N^2)$	$O(N^2d)^{**}$	$\{\mathbf{y}_i\}_{i=1}^N$	$O(Nd)$
	[42]	$O(N \log d + N^2)$	$O(N^2 \log d)^*$	$O(\log d)$	$O(1)$	$O(\log d)$	$\mathbf{y}$	$O(d)$
	[43]	$O(N \log d)$	$O(N^2 \text{poly}(\log d))^*$	$O(1)$	$O(1)$	$O(1)$	Probability of the predicted class	—
Quantum global attention	[23]	$O(N + d)$	$O(N \log d)$	$O(d)$	$O(N)$	$O(Nd)^{**}$	$\{\mathbf{y}_i\}_{i=1}^N$	$O(Nd)$
	[47]	$O(N \log d)$	$O(N \log^2 d + \text{poly}(N \log d))^*$	$O(1)$	$O(1)$	$O(1)$	Probability of the predicted class	—



潜在解决方向

• 量子轻量化设计:

- 替换标准Transformer为结构更简洁的变体（如MLP架构、稀疏注意力）。
- 在关键模块使用更浅的PQC或量子态复用技术减少资源消耗。

• 混合量子-经典架构:

- 保留更多经典运算模块，仅在局部引入量子模块以减少总体量子资源需求。
- 构建模块化量子组件以提升系统兼容性与扩展性。

• 优化量子编码与测量策略:

- 采用更高效的数据编码方法（如振幅编码、状态复用）。
- 优化测量设计，减少冗余测量次数，提高信息读取效率。

• 资源受限的特定任务优化

- 面向小规模任务或边缘应用设计专用量子模块，规避对大规模硬件的依赖。





当前的挑战

• Barren Plateau 问题

- 随着量子电路规模增加，梯度迅速消失，导致参数无法有效更新。
- 电路越深，训练难度越大。

• 参数优化困难：

- 参数化量子电路（PQC）本身存在非凸优化问题。
- 标准经典优化器（如SGD、Adam）在量子参数空间表现不佳。

• 量子梯度计算不稳定：

- 常用的参数偏移法计算梯度存在测量噪声影响。
- 梯度估计结果波动较大，影响收敛。

• 训练开销大

- 训练效率受限于硬件速度和测量次数。



潜在解决方向

• 浅层量子电路设计:

- 采用浅层PQC或局部量子模块缓解Barren Plateau问题。
- 控制电路深度，降低梯度消失风险。

• 局部训练与参数迁移:

- 采用分段训练，局部优化各量子模块后联合微调。
- 利用参数共享与迁移降低训练难度。

• 量子自然梯度优化:

- 基于Fisher信息矩阵定义自然梯度，实现更稳定、高效的参数更新。
- 避免常规优化器在量子参数空间中的不稳定性。

• 测量优化与梯度估计改进

- 减少测量次数，采用策略性测量或自适应采样提高训练效率。



Challenges on QLA-based Transformers

- **依赖容错量子计算机：**
 - QLA-based方法需要大规模、低噪声的容错量子硬件，目前难以实现。
- **量子存储与数据加载瓶颈：**
 - 大规模矩阵需编码为量子态，受限于量子存储能力和数据加载复杂度。
 - 振幅编码等方法在实际硬件上开销极高。
- **矩阵操作门数与电路深度极高：**
 - Block Encoding、QSVT等核心操作需要大量受控门与电路堆叠，电路深度远超PQC方法。
 - 导致硬件运行时间和误差积累难以接。
- **应用范围受限：**
 - 目前仅在理论层面展示指数加速潜力。
 - 难以在实际Transformer任务中实现端到端应用。



谢谢！

饮水思源 爱国荣校