云计算与人工智能前沿 · 2026 年秋

联邦微调综合项目

从大模型适配，到分布式训练与联邦学习

作业指导课

项目背景：银行客服意图识别

任务

判断客户的一句提问属于哪一类意图，共 77 类。

```
"How do I locate my card?"    → card_arrival
"My transfer failed, why?"    → failed_transfer
"I want to change my PIN."    → change_pin
```

难点：数据不能集中

- 对话数据分散在 10 家机构
- 出于隐私与合规，原始数据不能离开本机构
- 各机构业务不同，**数据分布差异很大**

> 三个任务：一台机器上用好大模型 → 多个进程协同训练 → 数据不出本地、还有各种限制时怎么训练好。

统一实验设置

项目	规定
基座模型	Qwen2.5-1.5B-Instruct
数据集	Banking77：训练集 9993 条，77 类
数据划分	课程统一发放 `split.json`：验证集 1001 条，其余分给 10 个客户端 三种划分：`iid` 均匀 · `dir1.0` 轻度不均 · `dir0.1` 严重不均
测试	任务一、二使用公开测试集（3076 条） 任务三由课程组用**未公开的测试集**统一评测
计算平台	交大超算 π2.0 `dgx2` 队列（V100 32GB）

> 全班同一模型、同一划分、同一评测脚本，结果才能相互比较。验证集用于调参，测试集只用于报告。

三个任务

20 分

任务一 · 大模型适配与推理

1. 零样本提示
2. 少样本提示
3. LoRA 微调
4. 推理性能测量

30 分

任务二 · 分布式训练与联邦学习

1. 多进程数据并行
2. 多进程联邦平均
3. 本地独立训练与对照

20 分

任务三 · 真实约束下的联邦挑战

- 只给场景、约束与指标
- 方法自定
- 按未公开测试集结果评定

任务一、二学习方法，按完成情况与正确性评定；任务三自主探索，依据最终测试指标并结合方法与分析评定。
第 13 教学周最后一天一次提交，第 14 教学周起课堂汇报。

任务一 · 20 分

大模型适配与推理

不训练能做到什么？训练后能做到什么？代价分别是多少？

预备知识：LoRA 微调

- **全量微调**：更新模型全部参数，1.5B 模型需要大量显存
- **LoRA**：冻结原有权重 W，只在旁边加一对小矩阵

  $W' = W + B \cdot A$

  A 为 r×d，B 为 d×r，秩 r 很小（如 8）
- 只训练 A、B 和分类头：本项目约 120 万参数，**不到总参数的千分之一**
- 训练完可把 B·A 合并回 W，推理不增加开销

为什么用在本项目

- 一张 V100 即可训练 1.5B 模型
- 联邦学习中客户端只需上传 A、B 和分类头，每次约 4.6MB

参考资料

- LoRA 原论文：arxiv.org/abs/2106.09685
- Hugging Face PEFT 文档：huggingface.co/docs/peft
- 大模型参考讲义第 21、38 页："预训练 + 微调"范式

任务 1.1　零样本提示　不训练

做什么

1. 以对话方式加载基座模型（`AutoModelForCausalLM`）
2. 在系统提示中列出 77 个类别名，要求模型只输出类别名
3. 对验证集每条提问生成回答（贪心解码，最多十几个 token）
4. 把回答映射到类别：完全匹配，否则取最接近的类别名
5. 计算验证集准确率

```
[system] Classify the banking customer query
into exactly one intent. Answer with the
intent name only.
Intents: activate_my_card, age_limit, ...
         (共 77 个)
[user]   Query: How do I locate my card?
         Intent:
[model]  card_arrival
```

需要记录	准确率、提示长度（token 数）、每条耗时、显存
思考	哪些类别容易错？回答不合法时怎么处理？

课程组试跑（验证集抽样 300 条）：**准确率约 43%**，提示约 400 token，每条约 0.08 秒。远高于随机猜（1.3%），但还不够用。

任务 1.2　少样本提示 不训练

做什么

1. 在 1.1 的提示中加入示例："提问 → 类别"
2. 示例从客户端训练数据中选取，**不得使用验证集或测试集**
3. 至少比较两种示例数量，如每类 1 例、每类 3 例
4. 可以尝试不同的选例方式（随机、按相似度检索等）

```
[system] ...（类别列表同 1.1）
Examples:
Query: I'm still waiting on my card.
Intent: card_arrival
Query: Can I change my PIN at an ATM?
Intent: change_pin
...（每类 k 例）
[user]   Query: How do I locate my card?
         Intent:
```

需要记录	不同示例数下的准确率、提示长度、每条耗时、显存
思考	示例越多越好吗？代价是什么？

课程组试跑：每类 1 例 **约 44%**（提示约 2100 token，0.15 秒/条）；每类 3 例 **约 59%**（提示约 5500 token，0.47 秒/条）。示例越多越准，但提示变长、推理变慢。

任务 1.3　LoRA 集中微调　训练

做什么

1. 把基座模型作为分类模型加载（`AutoModelForSequenceClassification`，77 类）
2. 加 LoRA（如 r=8，作用于 q_proj、v_proj），分类头一起训练
3. 合并 10 个客户端的全部数据训练若干 epoch
4. 每个 epoch 在验证集上评估，据此选择设置
5. 报告公开测试集结果，保存适配器，用 `evaluate.py` 检查能否加载

输入	`split.json` 中 10 个客户端样本的并集
输出	`final_adapter/`
需要记录	可训练参数量、显存峰值、每 epoch 时间、验证集与测试集准确率
意义	"数据可以集中"时的效果，是任务二联邦实验的参照上限
建议	先用 SmolLM2-135M 和少量样本调通，再换正式模型

课程组试跑（r=8，学习率 2e-4，批量 16，3 epoch）：**验证集约 89%，测试集约 91%**；可训练参数约 120 万，显存约 10.7GB，约 4 分钟。

任务 1.4　推理性能测量　部署

做什么

1. 加载 1.3 的适配器，fp16 推理
2. 取一批测试提问，在批量 1、8、32、128 下分别测量
3. 先预热一次；计时前后调用 `torch.cuda.synchronize()`
4. 计算每秒处理样本数、每批耗时，记录显存
5. 与 1.1、1.2 的每条耗时对比

思考　批量越大越快吗？在线服务和离线批处理该怎么选批量？

课程组试跑（V100，fp16）

批量	样本/秒	毫秒/批
1	32	31
8	235	34
32	540	59
128	513	250

规律：批量从 1 增到 32，吞吐提高约 17 倍；再增大吞吐不再提高，每批延迟却大幅增加。微调模型每条约 2 毫秒，3 例少样本提示每条约 470 毫秒。

任务一：提交与评定

① 报告·任务一章节（最重要），建议包含

- 每个子任务的做法：提示怎么写、示例怎么选、LoRA 与训练设置、推理怎么计时
- 1.1–1.3 对比表：方法、准确率、提示长度或可训练参数量、耗时、显存
- 1.4 吞吐与延迟随批量变化的图
- 分析：不训练与训练分别能做到什么程度，代价分别是什么；推理性能的规律

② 支撑材料

- 代码、运行输出、1.3 的适配器

评定

- 四个子任务全部完成
- 报告写清做法、结果与分析，数据与日志一致
- 结果合理
- 能在汇报中解释提示写法、LoRA 设置和推理规律

任务二 · 30 分

分布式训练与联邦学习

多个进程一起训练：每一步都同步，和每一轮才同步，有什么区别？

回顾：FedAvg 算法

Lecture 2 第 44 页

From SGD to FedAvg

$$F_k(w) = \frac{1}{n_k} \sum_{i \in \mathcal{P}_k} f_i(w)$$

$$g_k = \nabla F_k(w_t)$$

$$w_{t+1} \leftarrow w_t - \eta \sum_{k=1}^{K} \frac{n_k}{n} g_k$$

$$\forall k, w_{t+1}^k \leftarrow w_t - \eta g_k$$

$$w_{t+1} \leftarrow \sum_{k=1}^{K} \frac{n_k}{n} w_{t+1}^k$$

Algorithm 1 `FederatedAveraging`. The K clients are indexed by k; B is the local minibatch size, E is the number of local epochs, and η is the learning rate.

Server executes:

initialize w_0

for each round $t = 1, 2, \dots$ **do**

  $m \leftarrow \max(C \cdot K, 1)$

  $S_t \leftarrow$ (random set of m clients)

  for each client $k \in S_t$ **in parallel do**

    $w_{t+1}^k \leftarrow \text{ClientUpdate}(k, w_t)$

  $w_{t+1} \leftarrow \sum_{k=1}^{K} \frac{n_k}{n} w_{t+1}^k$

ClientUpdate(k, w): *// Run on client k*

$\mathcal{B} \leftarrow$ (split $\mathcal{P}_k$ into batches of size B)

for each local epoch i from 1 to E **do**

  for batch $b \in \mathcal{B}$ **do**

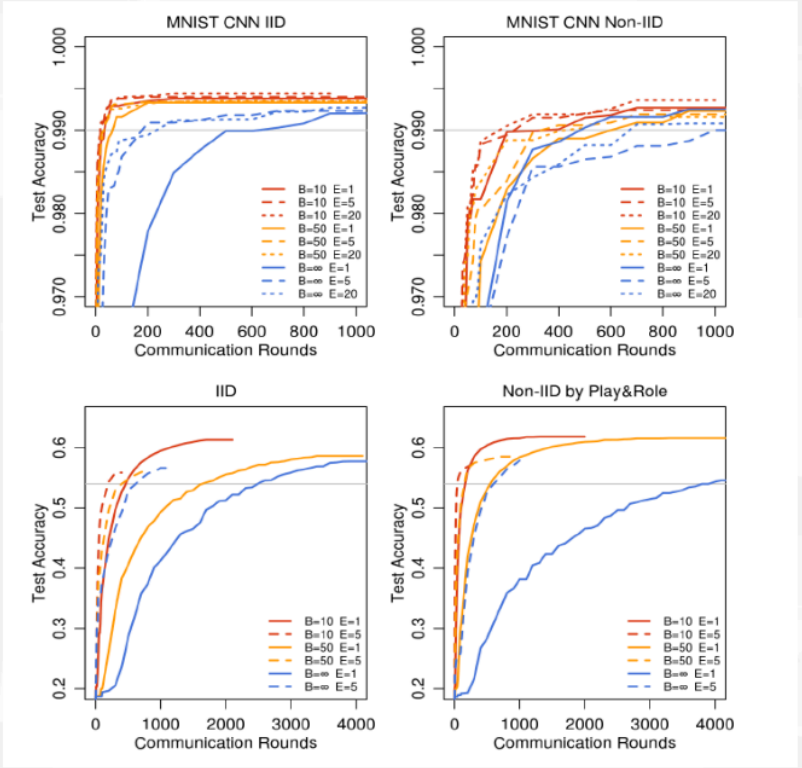
    $w \leftarrow w - \eta \nabla \ell(w; b)$

return w to server

回顾：IID 与 Non-IID

Lecture 2 第 45 页

Test Result



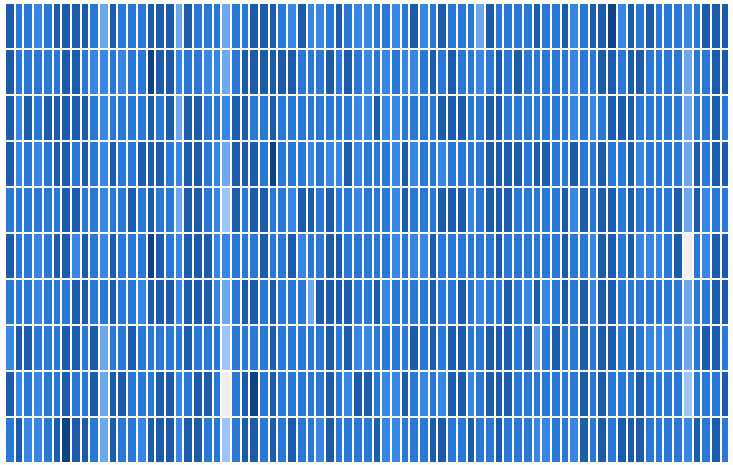
- Test set accuracy vs. communication rounds for the MNIST CNN (IID and then pathological non-IID) and Shakespeare LSTM (IID and then by Play&Role) with

- C = 0.1 and optimized η.

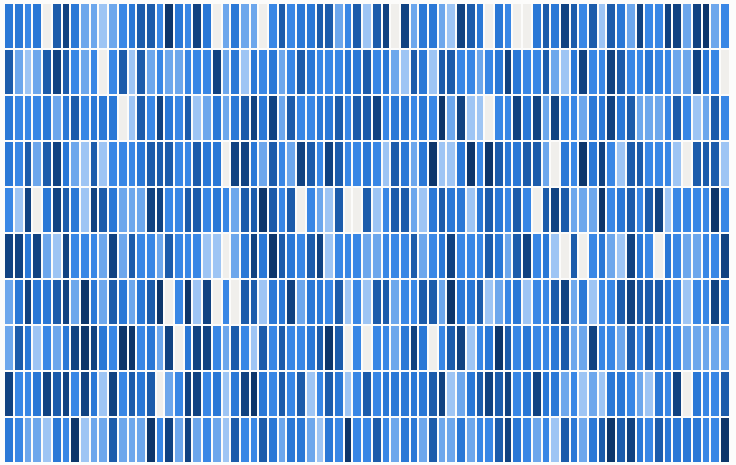
本项目的三种数据划分

每行一个客户端，每列一个类别；颜色越深，该客户端拥有该类别的样本越多

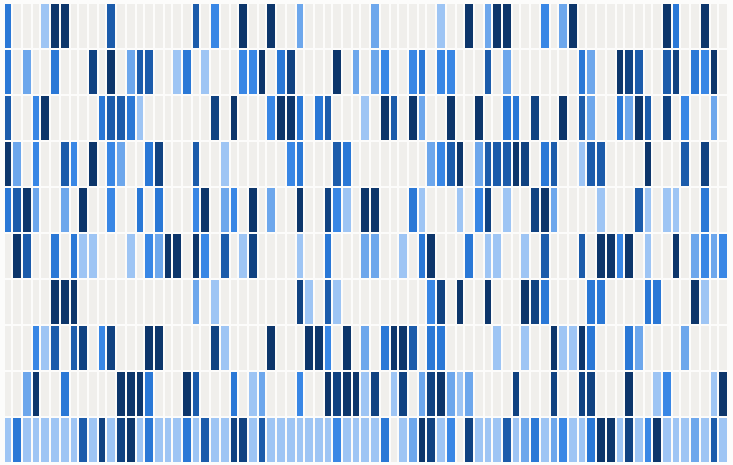
iid 均匀



dir1.0 轻度不均



dir0.1 严重不均



0 条 ≥ 60 条

iid 每家都有全部 77 类；dir0.1 下多数客户端只有 22–39 类，某些类别几乎只出现在一两家。

数据并行与联邦学习：区别在哪

	数据并行（分布式训练）	联邦学习（FedAvg）
数据	由训练方统一切分，各进程分布相同	天然分布在各机构，**不能移动**，分布各不相同
同步什么	梯度	模型参数（本项目为 LoRA 参数与分类头）
多久同步一次	**每一步**都同步（all-reduce）	本地训练若干步后，**每轮**同步一次
参与者	全部进程每步都参与	每轮只选部分客户端，可能掉线
结果	等价于单机大批量训练	受数据分布影响，可能明显变差

两者用同一种通信原语（all-reduce），差别在于"多久通信一次"和"数据能否随意切分"。

如何在一张 GPU 上做分布式

- 用 `torchrun` 启动 4 个进程，每个进程是一个"工作节点"
- 4 个进程共用同一张卡，通信后端用 `gloo`（NCCL 不支持同卡多进程）
- 课程提供 `job_dist.sbatch` 模板：
  `sbatch job_dist.sbatch 4 my_dist.py`
- 每个进程约 5.3GB 显存（基座以 fp16 加载），4 个进程放得下

```
import torch.distributed as dist
dist.init_process_group("gloo")
rank = dist.get_rank()        # 0..3
world = dist.get_world_size() # 4

# 把一个张量在所有进程间求和
t = torch.tensor([float(rank)])
dist.all_reduce(t)            # 每个进程都得到 0+1+2+3=6
```

任务 2.1　多进程数据并行

做什么

1. 4 个进程，合并全部客户端数据后均分，每个进程拿 1/4
2. 用 `DistributedDataParallel` 包装 LoRA 模型，反向传播时自动 all-reduce 梯度
3. 训练 2 个 epoch，进程 0 在验证集上评估
4. 统计通信量：每步同步的梯度大小 × 步数

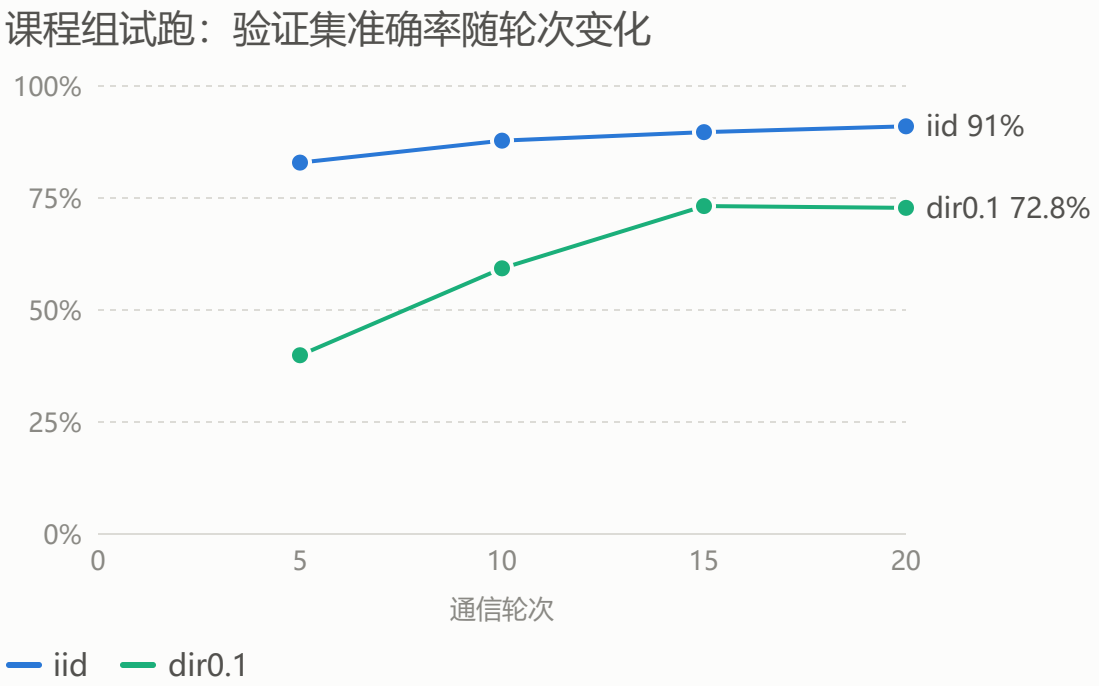
需要记录	每 epoch 验证集准确率、测试集准确率、累计通信量、总耗时、每进程显存
思考	与 1.3 单进程训练相比，结果是否一致？为什么？

课程组试跑（4 进程，每进程批量 16，2 epoch）：**测试集约 88%**；每 epoch 140 步，累计通信约 2580MB；约 3 分钟。

任务 2.2　多进程联邦平均

做什么

1. 10 个客户端由 4 个进程分担；所有进程用相同种子，每轮选出相同的 4 个客户端
2. 每个客户端从**本轮全局参数**出发，本地训练 1 个 epoch
3. 轮末对"样本数 × 参数"做 all-reduce，再除以总样本数
4. 在 `iid` 和 `dir0.1` 下各跑 20 轮，每 5 轮评估验证集
5. 用一个小例子自查聚合结果是否与手算一致



测试集：**iid 约 92%，dir0.1 约 75%**；20 轮累计通信约 740MB，约 8 分钟。

任务 2.3　本地独立训练与对照分析

做什么

1. `dir0.1` 下，每个客户端只用自己的数据训练 3 个 epoch，不与任何人交换
2. 10 个模型分别在同一验证集上评估，报告平均值与范围
3. 汇总任务一、二的结果，做一张对照表

需要回答

- 数据并行与联邦平均在通信量和效果上差多少?
- 数据越不均衡，联邦平均为什么越差?
- 本地独立训练说明了什么?

课程组试跑汇总

方式	准确率	通信量
集中微调（1.3）	91%	—
数据并行（2.1）	88%	2580MB
联邦平均 iid（2.2）	92%	740MB
联邦平均 dir0.1（2.2）	75%	740MB
本地独立 dir0.1	约 27%	0

本地独立为验证集平均，其余为测试集

任务二：提交与评定

① 报告·任务二章节（最重要），建议包含

- 代码结构：数据并行与联邦平均分别在哪里同步、同步什么
- 聚合自查的结果；通信量是怎么统计的
- 对照表与 2.2 的准确率–轮次曲线
- 分析：通信量与效果的取舍；数据分布的影响；本地独立训练说明了什么

② 支撑材料

- 代码、作业脚本、运行输出

评定

- 三个子任务全部完成
- 聚合正确，通信量统计合理
- 报告写清做法、结果与分析，数据与日志一致
- 结果在合理范围内

任务三 · 20 分

真实约束下的联邦挑战

数据不均、通信有限、设备有强有弱、还会掉线——怎样训练出最好的模型？

出发点：联邦学习的挑战

Lecture 3 第 4 页



任务三的场景：真实环境中的一轮联邦训练

服务器：持有全局模型，每轮选出最多 5 个客户端，把全局参数发下去（下发不计流量）

↓ 下发全局参数

客户端 2
正常设备
训练 1 遍本地数据
上传 ✓

客户端 4
弱设备
只能处理 160 个样本
上传 ✓

客户端 5
正常设备
训练 1 遍本地数据
上传 ✓

客户端 6
本轮掉线
(掉线表规定)
无法上传 ✗

客户端 9
正常设备
训练 1 遍本地数据
上传 ✓

↓ 上传更新（计入流量预算）

服务器只收到 4 份更新，其中一份来自"没训练够"的弱设备，各家数据还很不均衡——如何聚合？

全程上传流量预算：115 MB

不压缩时每份更新约 4.6MB，这一轮就用掉约 18MB；只够约 6 轮

任务三：场景与约束

请按照课程发放的 `scenario.json` 规定的场景完成。在满足全部约束的前提下，让全局模型的准确率尽可能高。

约束	规定	对应挑战
数据	`dir0.1` 划分；不得汇集原始数据；验证集与公开测试集不得用于训练；不得使用课程以外的数据或模型	统计异构
通信	全程**上传总量不超过 115 MB**，按实际上传字节数计	通信代价
轮次与参与	最多 40 轮，每轮最多 5 个客户端；每个客户端每轮最多遍历本地数据 1 次	通信代价
弱设备	客户端 0、4、7 每轮最多处理 160 个样本（批量 16 时即 10 步）	系统异构
掉线	第 r 轮掉线的客户端即使被选中也不能上传；选择客户端时不得利用当前及之后轮次的掉线信息	系统异构
选择依据	方法与参数只能依据验证集选择	—

起点：直接使用任务二的联邦平均（不压缩上传），预算只够约 6 轮，**验证集约 46%**。

任务三：读懂 scenario.json

```
{
  "partition": "dir0.1",
  "upload_budget_mb": 115,
  "max_rounds": 40,
  "max_clients_per_round": 5,
  "max_local_epochs": 1,
  "weak_clients": [0, 4, 7],
  "weak_max_samples_per_round": 160,
  "drop_table": [[0, 4], [6], [9],
                 [7], [4], ...]
}
```

- `drop_table[r]`：第 r 轮（从 0 开始）掉线的客户端
- 上传量按实际发送的张量字节数累计，**下发不计入**
- 程序读取这个文件，全班面对完全相同的场景
- 请在日志中记录每轮参与的客户端和累计上传量，报告中给出最终的累计上传量

任务三：提交与评定

① 报告·任务三章节（最重要），建议包含

- 方法：针对哪些约束、原理、参考了哪些资料
- 验证集上的对照：每项改动带来的变化，最好有多个随机种子
- 累计上传量等场景设定的遵守情况
- 分析：有效与无效的原因，局限与改进方向

② 支撑材料

- 最终适配器 `final_adapter/`（须能用 `evaluate.py` 加载）
- 代码、运行日志

评定

- 课程组用**未公开的测试集**统一评测（`evaluate.py`，截断长度 64）
- 该测试集由课程组另行编写，提问风格可能与公开数据略有不同，请关注模型的泛化能力
- 依据最终测试指标（准确率），并结合报告中的方法与分析评定
- 不符合场景设定的结果不予认可

> 方法不限，需要自己查阅资料、设计实验。改进没有效果时，如实报告并分析原因，同样有价值。

计算平台：交大超算

集群	队列	资源	用途
π2.0	`dgx2`	V100 32GB，单作业最长 12 小时	**正式实验**
π2.0	`cpu`	每核 4GB 内存	下载模型与数据
思源一号	`debuga100`	A100 切分实例，5GB 显存，最长 2 小时	小模型调试

使用规则

- 每人同时只能运行 **1 个作业、1 张 GPU**
- **登录节点禁止运行训练**，违者会被超算中心封禁账号
- 学生账号只能在校园网内使用，校外先连学校 VPN
- GPU 全校共享，临近截止排队明显变长——**尽早开始**

现场演示 ①：登录与查看 GPU

```
# 登录
ssh 你的账号@pilogin.hpc.sjtu.edu.cn

# 集群有多少卡、用了多少
sinfo -p dgx2 -N -O "NodeList:10,StateCompact:8,Gres:32,GresUsed:40"

# 自己账号能用几张卡：看第一行 GrpTRES 中的 gres/gpu=X(Y)
#   X 为上限（1 表示可用 1 张），Y 为当前已用
scontrol show assoc_mgr users=$USER flags=assoc | grep GrpTRES

# 申请一张卡，确认可用
srun -p dgx2 -N 1 -n 1 --cpus-per-task=6 --gres=gpu:1 --time=00:05:00 nvidia-smi
```

现场演示 ②：配置与提交作业

```
# 上传课程材料到 ~/fedlora 后
cd ~/fedlora && mkdir -p logs runs splits && mv split.json scenario.json splits/

bash setup_env.sh                          # 建环境（登录节点，约 5–10 分钟，只做一次）
sbatch download.sbatch                     # 下载模型与数据（CPU 作业）

sbatch job.sbatch my_train.py --seed 1     # 单进程作业（任务一、三）
sbatch job_dist.sbatch 4 my_dist.py        # 4 进程作业（任务二）

squeue -u $USER                            # 查看作业：R 运行中，PD 排队
tail -f logs/fl_<作业号>.out               # 实时输出
scancel <作业号>                           # 取消作业
sacct -u $USER -S 2026-09-01 -X -o JobID,JobName,State,Elapsed   # 作业记录
```

课程提供什么，你完成什么

课程提供

`split.json`	统一数据划分，**请勿修改**
`scenario.json`	任务三场景约束
`evaluate.py`	统一评测脚本
`setup_env.sh`	建立 Python 环境
`download.sbatch`	通过镜像下载模型与数据
`job.sbatch` / `job_dist.sbatch`	单进程 / 多进程作业模板
任务书、超算使用手册	详细要求与排错

你自己完成

- 全部代码
- 实验设计与运行
- 结果分析与报告
- 汇报幻灯片

> 可以使用任何参考资料和 AI 工具。你需要对提交的全部代码和结果负责，并能在汇报中解释。

提交与评分

第 13 教学周最后一天前，Canvas 一次提交

- 实验报告（PDF），按三个任务组织
- 全部代码与作业脚本
- 运行输出与日志
- 任务一的适配器、任务三的最终适配器
- 汇报幻灯片

评分

- 考勤 10% · 项目材料 70% · 项目汇报 20%
- 任务一、二：按完成情况与正确性评定
- 任务三：依据最终测试指标，并结合方法与分析评定
- 教师和助教审核提交材料，并结合课堂讲解与问答综合评定

课堂汇报

内容与形式自定，评分关注

- 结果与分析是否清楚
- 任务三的方法与效果是否讲清
- **关键代码讲解**：挑一两段你认为最关键的代码讲清做了什么、为什么这样写；讲了才有这部分分数
- 讲得好的亮点（如有价值的发现、失败的排查过程）会加分

安排

- 先陈述、后问答；时长与顺序另行通知
- 幻灯片随报告一起提交

会问哪些方面

- **数字**：报告或日志中某个数字是怎么得到的
- **设置**：参数为什么这样选，换一个值会怎样
- **方法**：任务三的方法解决了什么、是否稳定
- **发现**：围绕你分享的发现追问细节

> 问题围绕每个人自己的结果和做法，各不相同。

答疑

任务书 · 超算使用手册 · 课程材料 见 Canvas